TUGAS 2 : End-to-End Databricks Platform

Skenario: Anda adalah tim data yang bekerja di perusahaan Y yang menggunakan platform Databricks. Anda harus membangun *pipeline* otomatis yang memproses dataset dari **sumber data eksternal**, mengolahnya dengan **Spark**, membuat model **AI/ML** pada data tersebut, dan menguji model itu serta membuat **Dashboard**.

Catatan: Studi kasus yang digunakan bersifat bebas. Silakan mencari dataset yang bersifat *open access*

Ringkasan Proyek:

Komponen	Implementasi dalam Proyek Ini
G-Drive, Table, Volume	Dataset yang di-upload ke folder Google Drive, Github, dst
SQL	Anda akan melakukan *exploratory data* dengan membuat tabel **SQL** menggunakan **Spark**
ETL Pipeline (DLT)	**Harus memuat 3 layer:** 1. **Bronze** untuk membaca CSV baru secara *incremental*. 2. **Silver:** Menggunakan **Spark Dataframe** untuk membersihkan / persiapan data Bronze layer dan 3. **Gold:** Data bersih yang siap dibuat report dan dashboard
Jobs (Workflow)	Membuat **Job** yang dijadwalkan (misal: per 2 menit / ketika table update / file baru / dst) untuk **menjalankan DLT Pipeline (Bronze, Silver & Gold)** **Note:** Buktikan bahwa job ini berhasil
AI/ML	Buat model klasifikasi / regresi berdasarkan data dari **Silver layer**

Models & Serving	Mendeploy model dari *Experiments* sebagai **Endpoint API** yang aktif.
Pengujian	Menguji endpoint model melalui aplikasi **Postman**
Dashboard	Membuat **Dashboard** yang membaca dari tabel **Gold** dan **custom SQL**
Nilai Tambah (Opsional)	1. Tambahkan **sumber data gambar** yang relevan dengan studi kasus yang disimpan di **volume** 2. Buat **job scheduling** yang secara otomatis berjalan ketika terdapat **penambahan data gambar baru** 3. Latih/gunakan model **klasifikasi gambar** 4. Deploy model gambar ini sebagai **Endpoint API kedua**.

Submission

1. Terdiri dari 1-2 mahasiswa
2. **Progres Tugas:** *Selasa, 10 November 2026*
3. **Demo Tugas:** *Senin, 16 November 2026*

Referensi

Playlist Databricks:
https://www.youtube.com/playlist?list=PL5I6SZqMk8fGHI64dRINEwE0g7pmPzKCi

About Databricks

Databricks is the Data and AI company. **More than 10,000 organisations worldwide** — including Comcast, Condé Nast, and **over 50% of the Fortune 500** — rely on the **Databricks Lakehouse Platform to unify their data, analytics and AI**. Databricks is headquartered in San Francisco, with offices around the globe. Founded by the original creators of Delta Lake, Apache Spark™, and MLflow

https://www.databricks.com/company/newsroom/press-releases/databricks-doubles-anz-headcount-signalling-growing-demand